

Detección automática de metadatos identificatorios en sentencias judiciales

Claudio Sebastián Castillo

2022-11-03

Tema elegido

En este documento presentamos nuestro Plan de Tesis para la Maestría en Minería de Datos de la UTN -Regional Paraná- en el marco del área de Procesamiento del Lenguaje Natural (NLP), en el tópico *reconocimiento de entidades nombradas* (*Named Entity Recognition* o NER). El objetivo del trabajo es implementar algoritmos de aprendizaje automático orientados a reconocer y extraer *datos identificatorios* de sentencias judiciales. El dominio legal es un campo de producción de un gran volumen de información textual, cuyo contenido y alcance impacta de manera definitiva en la vida de muchas personas. Esta información es eminentemente no estructurada por lo que su exploración y explotación enfrenta grandes desafíos. Entre esos desafíos, la falta de recursos para el abordaje automatizado de textos en español, y particularmente la falta de un *corpus legal anotado* en este idioma ha sido una barrera infranqueable para el avance en las tareas NER.¹ Por ello, en este trabajo propondremos cambiar el alcance de la tarea de anotación y construir un *corpus legal semi-anotado* en español que nos permita desarrollar algoritmos de aprendizaje supervisado. Reduciremos el set de *entidades nombradas* al conjunto de *entidades que integran los metadatos identificatorios de una sentencia judicial*. Datos que, dada su importancia en el ámbito legal, están generalmente disponibles y convenientemente individualizados. Así, disminuyendo la dimensión del problema que enfrenta la tarea NER convencional donde los recursos son escasos, nos centraremos en resolver un problema NER no-convencional donde existen recursos suficientes. Hemos denominado a este enfoque como *reconocimiento de metadatos* o MER (*Metadata Entity Recognition*). Consideramos que lejos de ser una operación trivial plantea un avance significativo en materia de implementación pues resuelve un problema real: la generación manual de metadatos identificatorios de sentencias. Al mismo tiempo, constituye un avance en materia de conocimiento por la generación de un *corpus legal semi-anotado* y el desarrollo de algoritmos de aprendizaje supervisado para una tarea NER no-convencional.

Fundamentación

El reconocimiento y la clasificación de entidades nombradas NER es una de las tareas más comunes en el Procesamiento del Lenguaje Natural (Vajjala and Balasubramaniam 2022). Normalmente consiste en la identificación automática -sin intervención humana- de entidades nombradas en textos² y su asignación a determinadas categorías semánticas. Dada una secuencia de tokens $s = (w_1, w_2, \dots, w_N)$ la tarea NER implica producir una lista de la forma $(I_s, I_e, token)$ para cada unidad, donde I_s e I_e representan la posición inicial y final del token dentro de la secuencia.

Estas unidades o tokens refieren generalmente a entidades que puede aludirse mediante *nombres propios* -e.g. personas, organizaciones y localizaciones- aunque en la práctica se han extendido para incluir expresiones numéricas referidas a fechas y cantidades, o distintos tipos de entidades que varían según el dominio de interés.

¹En nuestro país no existen experiencias publicadas sobre aplicación de estrategias NER en el dominio legal.

²A partir de las expresiones lingüísticas que sirven, en una determinada comunidad lingüística, para referenciarlas.

Esta referencia a entidades puede consistir en expresiones lingüísticas simples o complejas, confiriendo a la tarea de reconocimiento automático un nivel de dificultad importante (Jurafsky and Martin 2021).

Según Li et al. (2020a) podemos agrupar las técnicas aplicadas en NER en cuatro tipos, a saber: 1) enfoques basados en reglas que no necesitan datos anotados porque descansan en la formulación particular de reglas lingüísticas, 2) enfoques basados en aprendizaje no supervisado que emplean algoritmos del mismo tipo (e.g. *clustering*) y tampoco emplean datos anotados, 3) enfoques basados en ingeniería de atributos y aprendizaje supervisado³, y 4) enfoques de aprendizaje profundo⁴ y representación distribuida de datos (*Embeddings*) capaces de generar automáticamente la representación óptima de la información disponible.

Estos últimos enfoques han generado un cambio de paradigma en el NLP en general y en las tareas NER en particular gracias a los buenos resultados obtenidos (Roy 2021). Estas nuevas arquitecturas han ganado en poder de representación a partir de las distintas capas o *layers* de procesamiento que aplican a los datos (de ahí la noción de *profundas*), logrando optimizar el aprendizaje de patrones y superando la eficacia de otros modelos en distintas tareas de análisis semántico (Kiela et al. 2021; Serrano et al. 2022a).

Según Li et al. (2020b) la fortaleza que presenta el aprendizaje profundo en las tareas NER se vincula a tres razones: 1) NER se beneficia de transformaciones no-lineales de los datos (generando un mapeo no-lineal entre input-output), algo que los modelos de DL pueden capitalizar a partir de la complejidad del procesamiento en capas y las funciones no-lineales de activación, 2) DL ahorra mucho esfuerzo en la ingeniería de atributos (aspecto de alto costo en el desarrollo otros tipos de modelos) debido a su capacidad de aprender automáticamente representaciones significativas de la información disponible, y finalmente 3) los modelos DL pueden optimizarse completamente de principio a fin a partir del algoritmo de *descenso de gradiente*, habilitando así arquitecturas complejas de procesamiento.

Junto con estas transformaciones en el plano del conocimiento y las metodologías disponibles, nuevos proyectos públicos y privados con eje en las *tecnologías del lenguaje* han ganado presencia en el campo científico y en el discurso público, colocando al NLP como tópico de interés general. En el ámbito del NLP en español se destacan proyectos interinstitucionales de alcance nacional como el *Plan de Impulso de las Tecnologías del Lenguaje del Gobierno de España* o *IBERLEGAL* dirigidos a fomentar el desarrollo del procesamiento del lenguaje natural y la traducción automática en lengua española. A nivel internacional el Proyecto de la Comunidad Europea *MIREL* dirigidos a promover el avance de las *tecnologías del lenguaje*, similar a *MARCELL*, entre otros. En el ámbito privado sobresalen organizaciones consolidadas, dedicadas parcial o exclusivamente a brindar servicios de NLP, a saber: OpenAI, DeepMind, Ought, Hugging Face, Cohere, entre una larga lista de proyectos disruptivos.⁵

Este escenario estimulante para el NLP impulsa la mirada sobre ámbitos con uso intensivo del soporte textual como potenciales espacios de aplicación. Entre ellos, el Estado y particularmente el Poder Judicial, presentan una larga tradición de procedimientos escritos con hondo impacto en la vida de las personas. Por eso, en el presente trabajo propondremos implementar estrategias NER no-convencionales en el ámbito judicial con el fin de generar herramientas de exploración-explotación que contribuyan a mejorar los servicios al ciudadano.

Situación Problemática

El Poder Judicial tiene la función constitucional de brindar justicia y al hacerlo velar por el Estado de Derecho y la resolución pacífica de conflictos. Esa tarea fundamental para la vida en comunidad tiene como producto central a la *sentencia o fallo judicial*: documento textual donde un juez reconstruye una situación problemática y fija la solución jurídica que corresponde. Tan importante es este documento que tiene la fuerza de una ley particular para las personas involucradas en el conflicto y el poder de un mensaje acerca de “lo justo” para toda la sociedad. Por eso Rosatti, juez de la Corte Suprema de Justicia de la Nación,

³Dentro de este grupo, que emplea una estrategia de clasificación multiclases, se han empleado distintos algoritmos, entre los que se encuentran: *Hidden Markov Models (HMM)*, *Decision Trees*, *Maximum Entropy Models*, *Support Vector Machines (SVM)*, y *Conditional Random Fields (CRF)*.

⁴Normalmente basadas en Redes Neuronales Profundas.

⁵Un artículo que repasa empresas y desarrollos puede consultarse aquí: <https://hbr.org/2022/04/the-power-of-natural-language-processing>.

resaltando la importancia del lenguaje, dice que: “*las sentencias deben ser profundas y claras [porque] todos deben saber qué está prohibido*”.⁶

En efecto, la *sentencia judicial* es un documento público que concentra todos los datos relevantes de una *proceso judicial*, desde referencias a las partes, lugares y fechas de una causa, hasta complejas descripciones de hechos y derechos.⁷ Tales atributos tornan a las *sentencias judiciales* en insumos esenciales para la actividad judicial y piezas de información de amplia publicidad. Por ello, su individualización precisa y práctica es muy importante no solo para permitir su fácil reconocimiento y comunicación, sino también para asegurar su referencia clara y unívoca.

Desafortunadamente existe una gran asimetría entre la importancia que tienen las sentencias judiciales como fuente de información y la escasez de desarrollos orientados a explotar sus atributos lingüísticos. Esa asimetría se explica, en gran medida, por la escasez de recursos en general para el NLP en español, y en particular para el español legal. En línea con esto Samy (2021) menciona entre los *retos* que enfrentan los proyectos de NLP en el ámbito legal en español a: 1) *El número limitado de recursos y herramientas adaptados al dominio*; 2) *La predominancia del inglés, ya que la mayoría de los recursos y las herramientas disponibles se desarrollan para el tratamiento de textos en inglés*; y 3) *Una adopción ralentizada de las tecnologías inteligentes en el sector legal y administrativo en comparación con otros sectores como el sector biomédico o financiero*. Por su parte Cardellino et al. (2017) refuerzan esta enumeración destacando que *existen muy pocos corpus legales anotados con anotaciones para entidades* [lo que] *constituye una importante barrera para la Extracción de Información*. Dificultades similares destacan Leitner, Rehm, and Moreno-Schneider (2019), Serrano et al. (2022b), entre otros.

Es importante remarcar de lo anterior que la falta de corpus legal anotado es particularmente crítico para avanzar en tareas NER. Las soluciones más novedosas y con mejores resultados para este problema emplean generalmente algoritmos de aprendizaje supervisado, que tienen a disposición datos de entrenamiento etiquetados. Es decir, datos donde las entidades nombradas ya se encuentran identificadas y asignadas a la categoría semántica de interés, y el algoritmo aprende a reconocer los patrones que asocian datos con categorías. En el caso del español legal dicho corpus no existe, y su creación implica un trabajo manual de anotación y validación de alto costo económico y de recursos. En este contexto se inscriben distintos proyectos tendiente a superar la dificultad. Por ejemplo, Samy, Arenas-García, and Pérez-Fernández (2020) destaca la creación de la primera tarea compartida en el marco de *IberLegal*⁸ con el propósito de crear un corpus de textos en español y evaluar la tarea NER enfocándose en cinco categorías: legislación, organización/entidades legales, Personas, Lugares y Expresiones Temporales. A pesar de estos esfuerzos a la fecha no se dispone de un corpus legal anotado con entidades.

Ante este problema, en el presente trabajo propondremos un enfoque distinto de la tarea NER que nos permitirá generar un *corpus legal semi-anotado* para desarrollar estrategias de aprendizaje supervisado. Para ello, la tarea de anotación de entidades en este trabajo tendrá un alcance específico, en el que no se requiere procesamiento manual, y descansa exclusivamente en el tratamiento computacional del lenguaje. Este direccionamiento de nuestro esfuerzo implicará la *anotación de aquellas entidades nombradas en el texto que coincidan con los metadatos regularmente empleados para identificar sentencias*. Estos *datos identificatorios* constituyen entidades *per se*, empleadas intensivamente en el dominio legal. Regularmente aparecen pre-anotados junto a cada sentencia o fallo judicial como metadatos para su identificación. Constituyen datos protocolares que sirven como referencia para designar un documento legal particular. Como muestra el gráfico que agregamos abajo, los mismos normalmente incluyen: fecha de la sentencia, partes del proceso (actora y demandada), tipo de proceso, órgano que dictó la sentencia y jueces que firmaron la sentencia.

Hemos denominado a este subtipo de procesamiento NER como “*reconocimiento de metadatos*” o MER (*Metadata Entity Recognition*). Consideramos que lejos de ser una operación trivial plantea un avance significativo en materia de implementación pues resuelve un problema real: la generación manual de metadatos

⁶Horacio Rosatti, presidente de la Corte Suprema de Justicia de la Nación (CSJN), apertura del “XV Congreso Nacional de secretarios letrados y relatores de Cortes y Superiores Tribunales de Justicia Provinciales y CABA”, STJER, 27/10/2022, accesible aquí

⁷Estos elementos se articulan mediante un discurso eminentemente técnico, que procede -a priori- a partir de una argumentación racional de la forma premisas-conclusión.

⁸<https://temu.bsc.es/iberlegal/>



PODER JUDICIAL
DE LA PROVINCIA DE BUENOS AIRES

JUBA - BASE DE JURISPRUDENCIA

VISUALIZACION DEL TEXTO COMPLETO

[Ocultar Datos del Fallo](#)

DATOS DEL FALLO

Materia:	LABORAL
Tipo de Fallo:	Sentencia Definitiva
Tribunal Emisor:	SUPREMA CORTE DE JUSTICIA DE LA PROVINCIA (SCBA)
Causa:	L. 119347
Fecha:	14/8/2019
Nro Registro Interno:	
Caratula:	Bernardi, Rubén Alberto contra La Segunda ART S.A. .Accidente de trabajo.
Caratula Publica:	Bernardi, Rubén Alberto contra La Segunda ART S.A. .Accidente de trabajo.
Magistrados Votantes:	Kogan-Pettigiani-Negri-Soria-de Lazzari-Genoud
Tribunal Origen:	TRIBUNAL DEL TRABAJO N° 3 - TRES ARROYOS (TT0300 TY)
NNF:	
Observación:	
Sentencias Anuladas:	
Alcance:	
Iniciales:	
Observaciones:	

[Imprimir](#) | [Descargar](#)

TEXTO COMPLETO

ACUERDO
En la ciudad de La Plata, a 14 de agosto de 2019, habiéndose establecido de conformidad con lo dispuesto en el Acuerdo 2078, que deberá observarse el siguiente orden de votación: doctores **Kogan, Pettigiani, Negri, Soria, de Lazzari, Genoud**, se reúnen los señores Jueces de la Suprema Corte de Justicia en acuerdo ordinario para pronunciar sentencia definitiva en la causa L. 119.347, "Bernardi, Rubén Alberto contra La Segunda ART S.A. Accidente de trabajo".

ANTECEDENTES
El Tribunal de Trabajo n° 3 del Departamento Judicial de Bahía Blanca, con asiento en la ciudad de Tres Arroyos, hizo lugar a la acción instaurada imponiendo las costas del modo que especificó (v. fs. 429/436 vta.).
Se dedujo, por la parte actora, recurso extraordinario de inaplicabilidad de ley (v. fs. 457/504).
Dictada la providencia de autos y encontrándose la causa en estado de pronunciar sentencia, la Suprema Corte resolvió plantear y votar la siguiente

CUESTIÓN
¿Es fundado el recurso extraordinario de inaplicabilidad de ley?

VOTACIÓN
A la cuestión planteada, la señora Jueza doctora Kogan dijo:
I. El tribunal de trabajo interviniente hizo lugar a la acción deducida por el señor Rubén Alberto Bernardi y condenó a La Segunda ART S.A. a abonarle la prestación dineraria por incapacidad laboral permanente parcial en los términos del art. 14 apartado 2 inc. "a" de la ley 24.557 (v. fs. 558/582 vta.).
Para así resolver, juzgó acreditado que el accionante trabajaba a las órdenes de Sergio Osvaldo Soule en el comercio de su propiedad desde el día 1 de abril de 2004; se lo encuadró en la categoría Ayudante del Convenio Colectivo de Trabajo 231/94; sus tareas consistían en la cocción de productos de panadería; que el día 11 de septiembre de 2007, cuando se dirigía desde el lugar de trabajo a su domicilio sufrió un accidente que le provocó la rotura del tendón de Aquiles del miembro inferior izquierdo, como consecuencia de tal infortunio el demandante presenta una lesión que lo incapacita en un 16,56% del índice de la total obrera y se le otorgó el alta médica el día 10 de marzo de 2008.
En este sentido, con relación al tipo de labores sobre los que se proyecta la minusvalía, el a quo señaló que el actor no aportó prueba que permitiera

Figure 1: Suprema Corte de Buenos Aires: metadatos y sentecia judicial.

identificatorios de sentencias. Al mismo tiempo, constituye un avance en materia de conocimiento por la generación de un *corpus legal semi-annotado* y el desarrollo de algoritmos de aprendizaje supervisado para una tarea NER no-convencional.

Finalmente, es preciso destacar que la tarea propuesta resulta fundamental en el ámbito institucional pues implica -nada más ni nada menos- la posibilidad de automatizar la extracción de metadatos identificatorios. Además, dicha extracción permitirá realizar tareas de más alto nivel como clasificación, comparación y búsquedas.

Objetivos

1. Construir un *corpus legal semi-anotado* con *datos identificatorios* de sentencias judiciales en base a la estrategia MER para probar soluciones de aprendizaje supervisado, y
2. Desarrollar distintos algoritmos de aprendizaje supervisado para el tratamiento de dicho corpus buscando las configuraciones con mejor performance.

Factibilidad y relevancia

El proyecto que hemos propuesto es factible porque disponemos de los medios requeridos para su ejecución y la convicción de su utilidad. Respecto de los medios requeridos cabe destacar que el área de investigación en NLP-NER, a pesar de sus jóvenes 30 años, ha visto un acelerado crecimiento en materia de recursos y enfoques disponibles (Roy 2021). Desde las primeras soluciones basadas en modelos lineales y reglas lingüísticas, hasta los actuales modelos no-lineales basados en redes neuronales profundas y representación distribuida de datos (*word/character embeddings*), existe un amplio espectro de enfoques para nutrir nuestros abordajes del problema ((Serrano et al. 2022b), (Li et al. 2020a)).

Aunque estos avances tienen como lenguaje objeto al inglés, no han dejado de impulsar en los últimos años un florecimiento del NLP en español. Gracias a ello, las carencias antes apuntadas han comenzado a revertirse parcialmente ofreciéndonos material de valor para nuestro proyecto cuyo detalle presentaremos en el *estado del arte*.

Respecto de la factibilidad para construir un *corpus legal semi-anotado* para este proyecto tenemos evidencia de las múltiples opciones disponibles. En nuestro experimento de construcción de corpus legal⁹ hemos trabajado con el portal de jurisprudencia del Poder Judicial de la provincia de Buenos Aires que brinda acceso público a fallos judiciales¹⁰. En esa experiencia construimos un dataset no anotado de 4299 sentencias judiciales y sus respectivos metadatos empleando el método de *scraping*. La información colectada está disponible en un repositorio de libre acceso.¹¹ Esta información consta de fallos judiciales completos y metadatos de la causa (materia, tipo de fallo, número de la causa, caratula, fecha de sentencia, magistrado y tribunal actuantes, entre otros), que brindarían -con el tratamiento apropiado- los insumos para una anotación parcial de entidades conforme al enfoque y objetivo propuesto en el presente trabajo.

Información similar a la obtenida de la justicia de Buenos Aires se publica por distintos Poderes Judiciales del país. Pese a las diferencias de formatos en general se repiten protocolos de publicación que permitirá disponer de un grupo de datos relativamente estable. Por esto entendemos que existe disponibilidad material y tecnológica para construir el corpus.

Abonando lo anterior, contamos con un ejemplo análogo de construcción de corpus en el trabajo de tesis de grado de Karen Haag bajo la dirección de Cristian Cardellino en la Facultad de Matemática, Astronomía, Física y Computación Universidad Nacional de Córdoba en el año 2019¹². El trabajo aborda el tópico NLP-NER aplicado al dominio legislativo, y el corpus empleado fue construido ad-hoc para la tesis mediante *scraping* del portal Infoleg¹³ según se detalla en el punto 3.

Luego de exponer los argumentos acerca de la factibilidad del proyecto es preciso mencionar las razones que hacen a su relevancia. En tal sentido mencionamos que nuestro trabajo realizará un doble aporte al campo NLP en español. Por un lado crearemos y haremos público un *corpus semi-anotado* con *entidades identificatorias* de fallos judiciales. Este dataset no resolverá la necesidad de un corpus legal anotado que hoy se plantea en el dominio, pero sí dejará disponible un recurso que permitirá probar y desarrollar soluciones de

⁹Accesible en github aquí: https://github.com/castillosebastian/nlp_research/blob/master/Crear_corpus_judicial_experimento0.ipynb

¹⁰<https://juba.scba.gov.ar/Busquedas.aspx>

¹¹https://github.com/castillosebastian/legal_corpus

¹²Accesible aquí <https://rdu.unc.edu.ar/bitstream/handle/11086/15323/Haag%2C%20K.%20Y.%20Reconocimiento%20de%20entidades%20nombradas%20en%20texto%20de%20dominio%20legal.pdf?sequence=1&isAllowed=y>

¹³<http://www.infoleg.gob.ar/>

menor escala ligadas a MER. Posibilidad que dada su vinculación con una necesidad institucional concreta y actual que viven las instituciones judiciales sin dudas será un aporte valioso para ellas. Por otro lado, buscaremos también realizar un aporte al campo NLP-MER en español aplicando algoritmos de aprendizaje profundo siguiendo los últimos avances en esta materia y publicando el código para su análisis y reutilización.

Respecto de la relevancia para las instituciones de justicia cabe señalar, en primer lugar, que el desarrollo de estrategias de NLP-MER brindará una herramienta de gran valor para el procesamiento de datos identificatorios de sentencias judiciales. El servicio de justicia se asienta sobre el intercambio de dicha información entre los distintos actores de un proceso: jueces, abogados y auxiliares de justicia. Ello sin mencionar a los intercambios que se generan en la red de instituciones públicas que participan de este servicio (i.e. Registros Públicos, Colegios Profesionales, Instituciones de Salud Pública y Asistenciales, entre otras). Contar con herramientas de NLP-MER aplicadas al ámbito legal permitiría automatizar el proceso de extracción de *datos identificatorios*, al tiempo que optimizará recursos en los Poderes Judiciales (Leitner, Rehm, and Moreno-Schneider 2019). Por ejemplo, proyectos vinculados a gestión electrónica, celeridad y regulación de flujos de información¹⁴ se beneficiarán con el desarrollo de sistemas inteligentes que permitan la identificación automática de sentencias judiciales (Samy 2021).

En segundo lugar, desde una perspectiva institucional de más amplio alcance, el desarrollo de estrategias NLP-MER podría extenderse a otros documentos con metadatos disponibles. En este caso, la posibilidad de desarrollar algoritmos sensibles a los atributos lingüísticos del texto liberaría posibilidades de automatización sin precedentes, elevando la calidad del servicio de justicia. En efecto, los grandes procesos de reforma judicial en los últimos años han establecido deberes de actuación exigentes a los órganos de justicia que demandan una capacidad de procesamiento de información sin precedentes.¹⁵ Este escenario es un espacio fértil para el desarrollo de las *tecnologías del lenguaje* que estudiaremos en este proyecto.

Por último, aunque el foco de nuestro trabajo está puesto en documentos judiciales, no es difícil advertir que el grueso de la administración pública (y buena parte de la privada) funciona con el soporte de documentos administrativos no estructurados o semi-estructurados. Por eso, los avances en el procesamiento de documentos judiciales presentan gran potencial de transferencia hacia otros dominios de la administración pública, multiplicando los potenciales beneficios sociales que tiene nuestro desarrollo (Samy 2021).

Estado del arte

Teniendo en cuenta las detalladas reseñas elaborada por Li et al. (2020a) y Roy (2021) sobre la tarea NER en general, vamos a centrarnos en los avances generados respecto de aplicaciones al ámbito legal.

En lenguas distintas al español, podemos mencionar a Leitner, Rehm, and Moreno-Schneider (2019) que proponen aplicar dos modelos basados en *campos aleatorios condicionales* (*Conditional Random Fields* o CRFs) y *redes neuronales recurrentes de memoria de corto y largo plazo* (BLSTM). El corpus legal empleado en este estudio consistió en 750 sentencias en idioma alemán, anotadas manualmente. La tipología de clases empleada incluyó 19¹⁶ categorías que pueden consultarse en su idioma original.¹⁷ Para esas dos arquitecturas se probaron tres modelos, obteniendo los mejores resultados con BLSTM (F1 95.4/95.9). Por su parte Chalkidis et al. (2021) proponen un proyecto de extracción de datos específicos de contratos en inglés, formulando así un antecedente valioso para nuestro trabajo. Informan detallados experimentos -con optimización de hiperparámetros- para distintos modelos de redes neuronales recurrentes: LSTMs, DILATED-CNNs, TRANSFORMER y BERT. Reportan los mejores resultados con el primer modelo, empleando representaciones distribuidas de palabras específicas del dominio (*word embeddings* mediante algoritmo *word2vec*).

¹⁴Desarrollos que en las instituciones de justicia adquieren cada vez mayor visibilidad e importancia - ver Soto, Andres, *Nuevas Tecnologías y Gerenciamiento de la Ofician Judicial*, publicado en *Nueva gestión judicial : oralidad en los procesos civiles*, Héctor M. Chayer [et al.] , CABA, Ediciones SAIJ, 2017.

¹⁵Nueva gestión judicial : oralidad en los procesos civiles, Héctor M. Chayer ... [et al.] ; coordinación general de Héctor M. Chayer ; Juan Pablo Marcet. - 2a ed ampliada. Ciudad Autónoma de Buenos Aires : Ediciones SAIJ, 2017.

¹⁶Que podrían traducirse como: persona, juez/a, abogado/a, país, ciudad, calle, paisaje, organización, empresa, institución, Corte, marca, ley, ordenanza, Norma Legal de la Comunidad Europea, regulación, contrato, decisión judicial y bibliografía legal.

¹⁷<https://github.com/elenanereiss/Legal-Entity-Recognition>

Otras implementaciones relevantes encontramos en Pais et al. (2021) que plantean una arquitectura basada en redes neuronales recurrentes BLSTM y una capa final CRF, con representación distribuida de datos (palabras y caracteres), diccionarios y afijos en idioma Rumano. Como dato interesante, los investigadores evalúan ensambles de modelos y logran los mejores resultados de los experimentos (F1 90.36). Por su parte Cardellino et al. (2017) proponen un trabajo para documentos en inglés dirigido no solo a la tarea de reconocimiento y clasificación, sino también vinculación de entidades a una ontología (LKIF-Wikipedia)¹⁸, reportando resultados en torno a F1 80% para distintos niveles de granularidad. La arquitectura experimentada en este trabajo incluyó a Máquinas de Soporte Vectorial (SVM), redes neuronales (NN) y redes entrenadas sobre inputs basados en representación distribuida de palabras (*Embeddings*). Finalmente, otros proyectos interesantes atacan problemas específicos en la tarea NER: Barriere and Fouret (2019) proponen un modelo MICA (*May I Check Again*) para resolver errores de escritura y tipeo en entidades mediante la generación contextualizada de candidatos, y Skylaki et al. (2020) aborda la tarea NER en documentos PDF con pérdida de información (*noisy text*) empleando una estrategia que no implica anotación de entidades sino su generación *en* el texto.

Dentro de los pocos trabajos actuales aplicados al español vamos a encontrar a Samy (2021) que se enfoca en textos legislativos. Este trabajo parte de un corpus legislativo en español no anotado y emplea una metodología híbrida para su anotación según cada tipo de entidad de la siguiente forma: 1) las *normas* se anotan con expresiones regulares y listas de nombres oficiales, 2) las *fechas* mediante expresiones regulares, 3) los *organismos* mediante listas oficiales, 4) los *lugares* mediante listas y 5) las *personas* mediante librería de procesamiento spaCy y listas. Además de lo anterior se validó manualmente y de forma parcial la anotación (no se ofrecen detalles del alcance). El resultado de todo este esfuerzo es un texto enriquecido con 10+ millones de entidades marcadas en los 144.5 mil textos de Leyes-Decretos. El procesamiento fue realizado a partir de redes neuronales convolucionales profundas (*Deep CNN* implementadas por la librería spaCy v3) con uso de representación distribuida (Serrà and Karatzoglou 2017). En este trabajo se reporta un F1 general de 93%, aunque los resultados no son reproducibles pues se no publicaron datos ni algoritmos.

Otra experiencia aplicada al ámbito legislativo -esta vez en nuestro país- encontramos en la tesis de grado de Karen Haag¹⁹, bajo la dirección de Cristian Cardellino. Aunque los resultados no son concluyentes por las dificultades afrontadas en la anotación del corpus, el trabajo se enfocó exclusivamente en la mención de normas (ley, decreto, resolución, etc.).

Desafíos

Como mencionamos antes la falta de disponibilidad de un corpus legal anotado en español constituye una importante barrera para el trabajo. Dicha carencia no solo afecta la posibilidad material de implementar estrategias de aprendizaje supervisado, sino también impide evaluar las soluciones desarrolladas a falta de métricas de referencia para comparar resultados. Esta dificultad ha sido remarcada por investigadores en relación al español (Samy 2021; Samy, Arenas-García, and Pérez-Fernández 2020), pero también en otros idiomas (Leitner, Rehm, and Moreno-Schneider 2019).

Entendemos que nuestro enfoque de la tarea MER nos permitirá sortear este problema, y disponer de un corpus semi-anotado que permita entrenar nuestros algoritmos y al mismo tiempo evaluar su eficacia.

Respecto de la posibilidad de emplear librerías especializadas para la tarea de anotación (e.g. spaCy, Stanza, entre otras) entendemos que los resultados no satisfactorios informados por otros estudios son una alerta importante a tener en cuenta (Samy 2021). En cualquier caso, buscaremos evaluar su implementación en caso de ser empleadas.

Finalmente, existen restricciones legales que deben tenerse en cuenta para el tratamiento de datos personales (Ley 25326). En este punto cabe tener presente que la información que emplearemos en nuestro estudio

¹⁸Tarea que en el ámbito legal es particularmente necesaria dadas las relaciones fuertemente estructuradas y jerarquías que predominan en este dominio, aunque su realización implica un alto costo en tiempo y recursos para desarrollarse y mantenerse.

¹⁹Trabajo realizado en la Universidad Nacional de Córdoba, FAMAF. En este proyecto se elaboró un corpus ad-hoc obtenido de InfoLEG y se enfocó la tarea NER en la detección de tipos de normas. Para ello se emplearon expresiones regulares, y un anotador semántico basado en CRF (disponible en la librería en Java, Stanford NER-CRF).

es información pública, suministrada por órganos oficiales y sus respectivos portales institucionales. No obstante lo cual, el desarrollo de algoritmos y sus resultados tendrá especialmente en cuenta que los mismos no impliquen sesgos potencialmente perjudiciales para personas o grupos sociales.

Metodología

Dividiremos nuestro trabajo en dos partes asociadas a los dos objetivos propuestos: la primera parte resolveremos la construcción de un corpus legal semi-annotado y en la segunda desarrollaremos distintos algoritmos de aprendizaje supervisado para el tratamiento de dicho corpus.

Primera Parte: *construcción de corpus semi-annotado*

El primer objetivo de este trabajo es crear un *corpus semi-annotado* con *metadatos identificatorios de las sentencias judiciales*. Los cinco tipos de entidades incluidas en esos metadatos son:

- fecha de sentencia,
- partes del proceso:
 - actora, y
 - demandada,
- tipo de proceso,
- órgano que dictó la sentencia,
- jueces que firmaron la sentencia.

La selección de estos metadatos se basa en su amplia disponibilidad debido a que constituyen las referencias mínimas necesarias para identificar un fallo judicial. Los protocolos empleados en este dominio para la cita de precedentes normalmente contemplan a este grupo de datos, por lo que su empleo es extendido. Además de ello, cada elemento de este grupo aporte información valiosa de distintas dimensiones del caso, a saber:

- tiempo,
- personas y dirección del vínculo judicial,
- tipología del proceso,
- referencia estructural-orgánica, y
- jueces.

Ver Samy (2021)

PreAnotación

- Tipología de categorías semánticas acorde al dominio.
- expresiones regulares: ej. fechas
- listas: leyes, organismos, lugares (países, comunidades autónomas, provincias y localidades, tipos de vía, etc. Para utilizar estas listas, fue necesario un proceso de depuración porque presentaban los mismos problemas señalados anteriormente. Además, se ha optado por excluir algunos nombres de localidades por su ambigüedad y por el posible ruido que puede causar en forma de falsos positivos. Por ejemplo, se han eliminado de la lista localidades como “María”, “Javier” o “Caso”).

- nombres propios (SGP), cargos y puestos

Entrenamiento de Modelo

-----Ademas se desarrollara a un aprendedor automatico simple *baseline*. Este aprendedor, a comparacion de las tecnicas de aprendizaje profundo, no requiere mucha experiencia ni tiempo para su construccion y posee menos parametros que las redes neuronales, que generalmente en arquitecturas complejas tienen una gran cantidad de parametros. Este servira como referencia para los demas aprendedores.

Obtención y preparación de datos

Procesamiento de datos

To adapt categories for the legal domain, the set of NE classes was redefined in the approaches described above. Thus, Dozier et al. [13] focused on legal NEs (e.g., judge, lawyer, court). Cardellino et al. [8] extended NEs on NERC level to document, abstraction, and act. It is unclear what belongs to these classes and how they were separated from each other. Glaser et al. [18] added reference [23]. However, this was understood as a reference to legal norms, so that further references (to decisions, regulations, legal literature, etc.) were not covered. (**leitner_fine-grained_2019?**)

3.1 Semantic Categories Legal documents differ from texts in other domains, and from each other in terms of text-internal, and text-external criteria [7,12,15,21], which has a huge impact on linguistic and thematic design, citation, structure, etc. This also applies to NEs used in legal documents. In law texts and administrative regulations, the occurrence of typical NEs such as person, location and organization is very low. Court decisions, on the other hand, include these NEs, and references to national or supranational laws, other decisions, and regulations. Two requirements for a typology of legal NEs emerge from these peculiarities. First, the categories used must reflect those entities that are typical for decisions. Second, a typology must concern the entities whose differentiation in decisions is highly relevant. (**leitner_fine-grained_2019?**)

Taxonomía de las categorías: 19! ver (**leitner_fine-grained_2019?**)

Ojo con la anonimización de sentencias debido a protección de datos personales.

Entrenamiento de modelos

Gutiérrez-Fandiño et al. (2021)

Evaluación

Las métricas son importante en los problemas de aprendizaje automático permitiéndonos cuantificar el rendimiento de nuestros modelos. Por eso, detallaremos a continuación las formulas que empleamos en la evaluación.

Considerando que:

- Positivos verdaderos (TP) son aquellas predicciones que realiza el modelo como positivas y realmente lo son.
- Negativos verdaderos (TN) son predicciones que realiza el modelo como negativas y realmente lo son.
- Positivos falsos (FP) son aquellas predicciones que realiza el modelo como positivas, pero en realidad son negativas.
- Negativos falsos (FN) son aquellas predicciones que realiza el modelo como negativas, pero en realidad son positivas.

Nuestras métricas son:

$$Exactitud = \frac{TP + TN}{TP + TN + FP + FN} \text{ Precisión} = \frac{TP}{TP + FP} \text{ Exhaustividad} = \frac{TP}{TP + FN} \text{ F1Score} = 2 \frac{Precision * Recall}{Precision + Recall} =$$

Además de estas métricas que usan coincidencias exactas para evaluar desempeño (*exact match*), utilizaremos métricas que usan coincidencias indulgentes (*lenient match*). Estas métricas se calculan con el índice de *Jaccard*, empleado para medir el grado de similitud entre las entidades del texto de referencia y las entidades predichas. La formula del índice es la siguiente:

$$J(ref, pred) = \frac{overlap(ref, pred)}{length(ref) + length(pred) - overlap(ref, pred)}$$

Donde J mide la relación entre la intersección y la unión de las entidades de la referencia y de la predicción. Lograr el valor 1 indicaría que se encuentra el grado máximo de similitud entre la referencia y la predicción, es decir, los límites de las entidades coinciden exactamente.

Modelo base (*Baseline*)

Como punto de referencia inicial para nuestro trabajo elaboraremos un modelo base a partir de una arquitectura estándar de redes neuronales profundas y un clasificador basado en máquinas de soporte vectorial. Estas últimas conforman un grupo de algoritmos de aprendizaje supervisado muy empleado en tareas NER.

Software

El trabajo se desarrollará utilizando el lenguaje de programación Python 3 y frameworks o librerías asociadas. . . . Para el entrenamiento y evaluación de los modelos de NLP propuestos se utilizarán las plataformas Google Colab y Kaggle las cuales brindan acceso gratuito a GPU's de alto rendimiento.

Cronograma

Cronograma Media página. En meses (Mes1, Mes2, etc.)

- Barriere, Valentin, and Amaury Foutet. 2019. "May i Check Again? – a Simple but Efficient Way to Generate and Use Contextual Dictionaries for Named Entity Recognition. Application to French Legal Texts," September. <http://arxiv.org/abs/1909.03453>.
- Cardellino, Cristian, Milagro Teruel, Laura Alonso Alemany, and Serena Villata. 2017. "A Low-Cost, High-Coverage Legal Named Entity Recognizer, Classifier and Linker." In, 22. Londres, United Kingdom. <https://hal.archives-ouvertes.fr/hal-01541446>.
- Chalkidis, Ilias, Manos Fergadiotis, Prodromos Malakasiotis, and Ion Androutsopoulos. 2021. "Neural Contract Element Extraction Revisited: Letters from Sesame Street," February. <http://arxiv.org/abs/2101.04355>.
- Gutiérrez-Fandiño, Asier, Jordi Armengol-Estapé, Aitor Gonzalez-Agirre, and Marta Villegas. 2021. "Spanish Legalese Language Model and Corpora," October. <http://arxiv.org/abs/2110.12201>.
- Jurafsky, Daniel, and James H. Martin. 2021. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. 2021st ed. <https://web.stanford.edu/~jurafsky/slp3/>.
- Kiela, Douwe, Max Bartolo, Yixin Nie, Divyansh Kaushik, Atticus Geiger, Zhengxuan Wu, Bertie Vidgen, et al. 2021. "NAACL-HLT 2021." In, 41104124. Online: Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.naacl-main.324>.

- Leitner, Elena, Georg Rehm, and Julian Moreno-Schneider. 2019. “Fine-Grained Named Entity Recognition in Legal Documents.” In, edited by Maribel Acosta, Philippe Cudré-Mauroux, Maria Maleshkova, Tassilo Pellegrini, Harald Sack, and York Sure-Vetter, 272–87. Lecture Notes in Computer Science. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-33220-4_20.
- Li, Jing, Aixin Sun, Jianglei Han, and Chenliang Li. 2020a. “A Survey on Deep Learning for Named Entity Recognition,” March. <http://arxiv.org/abs/1812.09449>.
- . 2020b. “A Survey on Deep Learning for Named Entity Recognition,” March. <http://arxiv.org/abs/1812.09449>.
- Pais, Vasile, Maria Mitrofan, Carol Luca Gasan, Vlad Coneschi, and Alexandru Ianov. 2021. “Named Entity Recognition in the Romanian Legal Domain.” In, 918. Punta Cana, Dominican Republic: Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.nllp-1.2>.
- Roy, Arya. 2021. “Recent Trends in Named Entity Recognition (NER),” January. <http://arxiv.org/abs/2101.11420>.
- Samy, Doaa. 2021. “Reconocimiento y clasificación de entidades nombradas en textos legales en español.” *Procesamiento del Lenguaje Natural*, January, 103–14. <https://doi.org/10.26342/2021-67-9>.
- Samy, Doaa, Jerónimo Arenas-García, and David Pérez-Fernández. 2020. “Legal-ES: A Set of Large Scale Resources for Spanish Legal Text Processing.” In, 3236. Marseille, France: European Language Resources Association. <https://aclanthology.org/2020.lt4gov-1.6>.
- Serrà, Joan, and Alexandros Karatzoglou. 2017. “Getting Deep Recommenders Fit: Bloom Embeddings for Sparse Binary Input/Output Networks,” June. <http://arxiv.org/abs/1706.03993>.
- Serrano, Alejandro Vaca, Guillem Garcia Subies, Helena Montoro Zamorano, Nuria Aldama Garcia, Doaa Samy, David Betancur Sanchez, Antonio Moreno Sandoval, Marta Guerrero Nieto, and Alvaro Barbero Jimenez. 2022b. “RigoBERTa: A State-of-the-Art Language Model for Spanish,” June. <http://arxiv.org/abs/2205.10233>.
- . 2022a. “RigoBERTa: A State-of-the-Art Language Model for Spanish,” June. <http://arxiv.org/abs/2205.10233>.
- Skylaki, Stavroula, Ali Oskooei, Omar Bari, Nadja Herger, and Zac Kriegman. 2020. “Named Entity Recognition in the Legal Domain Using a Pointer Generator Network,” December. <http://arxiv.org/abs/2012.09936>.
- Vajjala, Sowmya, and Ramya Balasubramaniam. 2022. “What Do We Really Know about State of the Art NER?” May. <http://arxiv.org/abs/2205.00034>.